

“大模型：从基础到实战”课程收获

张馨洁

证号：2600940767

现在“大模型”是一个非常“火”的词，而且我的专业是计算机科学与人工智能，未来也打算从事 AI 相关工作，所以当我选择北大暑期学校课程时，我基本没什么纠结就选择了这门课程。由于我目前还是处于本科一年级阶段，我的主要的学习目标就是对大模型有一个大概的了解。在这两周的学习过程中对我很多概念比较陌生、有很多疑问，所以我准备在这篇文章梳理课上所学并着重用我自己的语言解释一些名词或概念。

从人工智能到大模型

智能是通过媒介来预测未来的能力。而媒介可以是任何语言（包括特定学科语言）、视觉信息、嗅觉信息、触觉信息等。而这个定义也暗含了训练人工智能的真正办法——通过各种媒介信息来训练，使人工智能学会预测。但在训练之前，我们必须明白：人工智能是一门技术，并非一门学科。目前没有智能原理，但仍然可以先探索技术。好比飞机是先被莱特兄弟造出来才有了空气动力学。也如 Theodore von Kármán 所言：Scientists discover the world that exists; engineers create the world that never was.

1956 年“人工智能”这一概念诞生。但在早期，训练人工智能的方式是人先去学习，写成规则以后转化为代码再让机器执行，如 John Searle 提出的“中文屋”。而又如 Stevan Harnad 所提出的“符号接地问题”（“Symbol Grounding Problem”）：计算机处理的是符号，但这些符号本身没有意义，它们不连接真实世界中的任何东西，纯靠句法运算、只悬浮在符号之间的系统，到底如何能产生真正的语义、真正指向现实世界？对此联结主义者（Connectionist）认为智能必须有头脑和生理基础，构造人工智能必须先构造神经网络和训练神经元。而 1985 年的反向传播算法（左侧输入，右侧输出，根据预期差距调整中间系数）和 1989 年的万能近似定理（一层足够宽的神经网络，理论上有能力学会任何复杂规律）为训练神经元突触提供了可能。深度学习就是机器基于多层神经网络、反向传播算法、人类提供的数据集自动调整中间系数以实现模拟智能行为的过程，是联结主义的工程实现。从另一个角度来说，行为主义（Actionism）认为智能是在主体与环境的互动中产生的，也应该把机器放入真实的自然环境中自然习得智能。

大模型就是利用深度学习技术实现的模拟全才行为的神经网络模型，是人工智能的一个实现方式。大模型大致可以被分为两类。一是语言模型，主要用于接收文本和生成文本，第二是多模态模型，除了具备语言模型能力外，还可以接收视频、音频、图片等多种媒介的信息来源并且生成多形态的信息。

2003 年 Bengio 提出的神经概率语言模型（把每个词映射成 m 维实数向量，语料序列前 $n-1$ 个词的对应向量连接起来作为输入，第 n 个词对应向量作为输出）是语言模型真正意义上的起点。在一定的限度内，维度越多，这个词向量代表的含义就越丰富，根据前几个词向量预测的下一个词就越精准；最初词向量和网络参数是随机生成的，但在训练过程中可以同时训练词向量（word embedding）和网络参数（中间系数即模拟神经突触）。Word2Vec（2013）是对“神经语言模型”的简化优化，提高了词向量训练效率。2017 年谷歌提出的 transformer 既使用词向量，又使用 attention 注意力机制（可以抓取全局任意位置信息）。2018 年 OpenAI 提出的 Generative pre-trained Transformer（预训练模型）用 Transformer 的解码器（基于上文理解或生成），沿用前 k 个单词预测第 $k+1$ 个单词，自监督（机器自己根据被给予的文本出题、自己做、自己对答案的训练过程）地训练深度学习神经网络。

具身智能是大模型加上机器实体，其具备感知外界、获取信息并且做出对应行为的能力。

从自然语言处理到词向量技术

自然语言处理（NLP，Natural Language Processing）的核心任务是建立可计算的模型，用于机器分析、理解、生成人类语言。计算机科学是研究自然语言处理的工具、语言学是处理对象、数学是建模工具。自然语言处理的终极目标是计算机可以和人类用自然语言交际。

在早期，NLP 的上游基础步骤主要是词法分析、句法分析和语义角色标注这三部分，这三部分就是为了让机器理解文本。词法分析就是给中文句子里加类似英文句子里的空格用于划分词语、给句子里的词标注词性和识别句子里面的专有名词、时间、数据等。句法分析是分析句子的主谓宾结构和句子中的短语结构以理解文本信息的过程。语义角色标注就是以句子的动词为中心，把谁、什么时候、在哪里、用什么东西、对什么、干了什么标注出来。这些步骤既会在传统 NLP 建模中出现也会在工业 NLP 建模中出现。建模路线和技术路线的关系可以类比为做数学题——建模范式是解题思路，技术路线是实现解题思路的知识点。NLP 建模从早期的还原主义（各个步骤按顺序分开处理（多个独立模型串行执行）输入导致错误累积，误差大）到现代的 Transformer 端到端（整体主义，一端是输入，另一端是输出，中间过程由模型处理）变化。基于规则的技术路线：主要是人工编写规则机器执行，但是人工很难穷尽所有规则，所以机器在这个阶段只是僵硬地执行规则，随机应变能力差。统计机器学习的技术路线：它不用人工总结语言规律就可以通过概率匹配和生成文本，但是 One-hot 编码和 N-gram 语言模型使得一旦机器要理解长上下文或者出现概率小的词语成本就会急剧上升。后来出现的 Word2Vec 可以被分为 CBOW（用上下文预测中心词）和 Skip-Gram（用中间词预测上下文）两套训练方式，解决了高维稀疏的问题和

不存在语义联系的问题。Word2Vec 最终的目标产物就是给每个词匹配一个低维稠密含语义的向量，实际操作中用负采样替换全局 Softmax 大大提高了训练效率。但是目前，NLP 的主要使用的技术是 Transformer 预训练模型（端到端、理解多义词、预训练+微调）。

数据处理与数据集

大模型的能力取决于三个方面：模型、数据、算力（Scaling Law），所以模型、数据和算力要同步提升，大模型能力才能整体提高、收益才能最大化。符合以下六个特征的数据是好的：正确性、多样性（不同主题、语言、风格、任务）、代表性（接近未来真实使用场景）、新鲜度（能覆盖新的知识和事件）、可追溯（知道数据来源、处理流程）、可合法使用（授权、隐私）。特别是在 2026 年以后，当高质量公开文本越来越稀缺，数据竞争会从“谁收集得更多”转向“谁构造得够好”。以下八步为大模型数据生命周期——原始数据、清洗过滤、预训练数据、指令数据（题目加答案）、偏好/奖励数据、多模态数据（图像、视频、音频、表格、文档等多模态对齐数据）、agent 轨迹数据（解题过程）、持续反馈数据（根据用户体验优化）——这整个周期就是 AI 的自净化。

数据指的是零散的信息，可以泛指所有素材。而数据集是归类整理好的信息。原始网页数据也就是 Common crawl 不是可以直接被拿来训练的教材。这些“脏”的数据可能有以下特征：噪声（广告、导航栏、评论区、乱码）、重复（转载文章、镜像网站、模版页面）、低质量（灌水、seo 垃圾、无意义文本）、风险内容（隐私、敏感信息有害内容）、数据分布不均（中文少、英文多、专业领域少）。

数据清洗主要是以下两个方式：规则过滤（人工总结规则）、模型过滤（模型自动筛选打分）。合成数据（模型生成、改写、扩写缺乏内容）术语增加数据的方式。以上是为了达成预训练和指令微调这两个阶段。预训练是为了增加大模型的知识储备和理解文本的能力，微调的目的是提高大模型完成人类指令的能力。偏好数据、推理数据、可验证数据这三类数据是 SFT（指令微调）后的提高大模型指令完成质量的数据。

在实际的数据生命周期内，Kernel 工程加快教学进度，Hiking 不允许考题出现在平时的作业里面防止大模型作弊。

Transformer 架构

Transformer 相比之前的神经网络结构可以在输入文本时并行计算句子中的每一个 token、拥有调取更长上下文中有用信息的能力、多种语序记录方式能更好理解和生成文本、可以理解言外之意。从宏观来看，Transformer 是由 Encoder 编码器和 Decoder 解码器组成的。Encoder 主要负责 NLU，Decoder 主要负责 NLG。在进入编码器和解码器之前要先进入 Embedding 嵌入层，对输入的所有 token 进行词嵌入和位置编码（绝对与相对位置

编码、旋转位置编码)。词嵌入是确定 token 意义的, 位置编码是确定词序的。Transformer 里面有很多 Encoder 层, 也有很多 Decoder 层。Encoder 由层归一化 LayerNorm 和多头注意力机制、然后残差运算投入 LayerNorm 和逐位置前馈网络 FFN (后替换为 MoE 稀疏层)、再通过残差运算后输出。词嵌入和位置编码以后分别得到词向量和位置编码向量, 两者相加融合得到的新向量进入到 Encoder 层。LayerNorm 把每个 token 的向量按特定标准统一方便计算, 多头注意力机制是用来理解不同 token 之间的关联, 再按照新理解的语义 (token 权重) 给 token 计算新的向量, 再通过残差连接 (加上 token 的原向量) 在理解语义基础上保留 token 原意, 接下来再次经过层归一层进入逐位置前馈网络深挖每个 token 的意义 (FFN 是稠密层、MoE 是稀疏层就是更有重点), 接下来再次通过残差连接 (保留词语原意)。经过多层 Encoder 完整理解输入含义后, 向量进入 Decoder。Encoder-Decoder 架构下的 Decoder, 单层结构: 先经 LayerNorm 归一, 再执行掩码多头自注意力并做残差连接; 再次经过 LayerNorm 归一, 执行交叉注意力并做残差连接; 再经过一层 LayerNorm 归一后送入 FFN / MoE 层并完成残差连接。Encoder 输出的向量和 Decoder 不断更新的向量就是 Decoder 预测输出的依据。与 Encoder 不一样的地方是, Decoder 掩码多头注意力机制 (掩盖后文通过梳理前文句法) 保证语句通顺, 交叉注意力机制则是在预测下一个 token 时结合原文 (Encoder 生成的原文语义向量) 防止意思跑偏。最后, 根据 Decoder 生成的特征向量找到对应的词, 再根据 Softmax 层算出概率最高的词作为输出。

大模型安全

原始训练出来的语言模型没有价值观, 为了缓解社会危害并且确保公平性, 使语言模型生成的内容与人类的价值观对齐非常有必要。对齐的三大目标是: helpful、harmless、honest。对齐的核心定位是让模型从“会续写”变成“会按人类期望完成任务”。RLHF 人类反馈强化学习是业界第一个成熟、标准的大模型对齐流水线, 分为三个阶段——第一步是 SFT 监督微调: 由人工出题并且给出标准答案, 让 AI 模仿人类标准答案; 第二步是 RM 奖励模型训练: 把模型针对同一问题给出的不同答案打分; 第三步是 PPO 近端策略优化: 加入一个辅助网络来预估大模型生成内容的得分情况, 从而帮助大模型生成更多高分内容。但是由于 RLHF 是由人工出题评判, 导致成本高、效率相对低, 于是出现了一些降低成本的办法。RLAIF AI 反馈强化学习: 用一个已经对齐的大模型去代替 RLHF 中人的职责。宪法 AI: 制定 AI 生成内容“宪法”, 模型生成内容后自己对照宪法检查。还有一些节约算力的方法。GRPO 组相对策略优化: 把同一个问题的一组回答打分。DPO 直接偏好对齐 (工业主流): 人工对比同一个问题的两条答案, 选出更优的一条, 构造一个函数提高模型生成更优答案的概率。使得对齐失效的四种情况: 越狱攻击、提示注入攻击、幻觉、AI 欺骗。不过对此业界也有应对方案。输入输出检测: 把开源模型做成检测器。底层模型微

调防御：设置系统内的安全指令优先级大于用户输入指令；IH-Challenge 数据集相当于习题集与试卷，是与系统内安全指令冲突的指令的集合，旨在训练与检测模型。

语言大模型

Transformer 不等于大模型，而是目前商用大模型唯一主流基础架构。主流大模型等于 Transformer 加上配套训练加上 Scale up（规模放大：参数量、训练数据、算力）。生产大模型必须具备的三个条件是大数据、大算力和强算法。大数据：希望穷尽人类历史上所有文本数据。2022 年 11 月 30 日 ChatGPT 发布开启通用大模型研发潮流，是语言大模型领域的 GPT 时刻。GPT 是自左向右预测（由前 K 个 token 预测第 K+1 个 token），几乎只能干预未来这件事（非常擅长语言生成）。BERT 同时利用上下文信息理解但无法生成。T5 理论上融合 GPT 和 BERT 优点，但实际应用未取得成功。GPT、BERT 和 T5 都是 Transformer 的衍生架构。除了之前提到的 RLHF、SFT，对比学习（在向量空间中，语义相似样本向量拉近，反之推远，从而辅助大模型理解文本）也是一种辅助的大模型训练方式。

训练框架与大模型评价

代码大模型生成代码容易出现幻觉，可以通过三重校验提高代码正确率。第一，模型自检查；第二，把代码放到沙盒（独立隔离的环境，防止恶意代码攻击）测试能否成功运行；第三，让另外的模型或者人工再次审核。评测是模型进化的关键，可以量化地跟踪领域（各类任务）进展。评测不是验收，而是训练控制回路（定义目标—动态运行—聚合诊断—反馈训练/部署）。动态运行就是让模型做题然后记录错题；聚合诊断就是找出所有错题的错误原因；部署就是上线。评测分为主观评测（人工）和客观评测（机器）。客观评测分为绝对评测（统一打分标准，所有模型按照这个打分标准对答案）和对比评测（把两个模型放在一起对比答题情况）。

具身大模型

具身智能是 AI 行业的下一个 GPT 时刻。传统多模态大模型不能直接作为具身智能大脑，具身智能有两大新增问题：要和物体在哪里交互；要怎么和物体交互。具身智能有三大主流技术路线：视觉-语言-动作模型 VLA、VLM（Vision-Language Model）大脑+VLA（Vision-Language-Action Model）小脑技术路线、世界模型 WM（World-Action Model）。第一种技术路线是基于 Transformer 模型，输入图像和文字指令，机器人直接输出动作，但是只能解决当下一个问题处理一件事，应对突发情况能力差。第二种技术实现方案把 VLM 作为慢系统（陌生的任务、陌生的环境、纠正执行错误），把 VLA 作为快系统（熟悉的任务），但是大小脑传输信息时存在损耗。不过机器人做过的事情会越来越多，没遇到

过的情况会越来越少，可以通过专家反馈把经验转化到快系统之中，减少对慢系统（推理）的依赖。世界模型指的是模型先学习世界运行的规律在预测环境后在生成动作。

多模态大模型

多模态大模型可以处理多种形态的信息载体（包括但不限于文本、图像、视频、音频、3D 模型）。多模态大模型用图像和文本配对的数据、用图文交错混合文档、视频和文本配对数据、视频和音频组合数据来训练。图像的全局相关性弱、局部相关性强，原始像素语义稀疏，不像文本 token 自带语义信息。多模态大模型有特殊的预训练（用海量弱标注数据训练出一个通用的半成品模型）方式（比如 MAE 掩码建模：掩盖像素再还原、对比学习：图文对比、自回归建模：把预测下一个 token 应用到图像视频领域）。这些训练的最终目标是多模态统一。跨模态对齐的核心模型底座是 CLIP 对比语言-图像预训练（Contrastive Language-Image Pre-training），可以把图片文字映射至同一个语义空间。

大模型与智能体

原生语言大模型只能回答训练时学到的知识，无法接触外部信息。Chatbot 就是 LLM 加上固定系统 prompt，拥有静态数据，也不会主动收集信息。Workflow 则是代码提前写好步骤，模型只能填充文字。Agent 可以自主决定流程、选择工具，它的核心能力是推理和规划，工作流程是：状态、上下文、行动、反馈、终止。增强大模型在原生大模型的基础上增加了检索、工具、记忆这三个功能。所有 Agent 都是增强 LLM，但增强 LLM 不一定是 Agent。Agent = LLM + Harness（接口层：Augmented LLM 的工具和检索、状态层：Augmented LLM 的记忆、控制层：统筹管理）

这是我和 AI 各搭建一半的我们店的智能导购 <https://furnitureagent-22bz3k4x2ptc9zj3rqb8zq.streamlit.app/>，算作结课小实践。
<https://github.com/Jade681/furnitureAGENT> 这是这个实践的代码仓库。

（字数：5708）